

高级算法设计与分析 Lecture 5

授课时间: 2020 年 4 月 12 日 授课教师: 孙晓明

记录人: 吴昊

1 代数化方法

代数化方法 (Algebraic Techniques) 是指将问题用代数的形式表示, 将其转化为一个代数问题, 从而可以借助代数中的定理与性质。前面课程中提到过“矩阵乘法验证”问题和“判定两个文件是否相同”问题都是代数化方法实际运用的例子, 下面我们通过图论中的“完美匹配”问题进一步理解这一方法。

1.1 完美匹配问题

无向图 $G(V, E)$ 的一个匹配 (matching) 是边集 E 的一个子集, 并要求该子集中的边没有公共顶点。如果一个匹配覆盖了顶点集 V , 则称它是一个完美匹配 (perfect matching)。完美匹配问题是要判断一张图中是否存在完美匹配。

在我们下面的讨论中, 我们只讨论二部图的完美匹配问题。如果无向图 $G = (V, E)$ 的顶点集 V 可分割为两个互不相交的子集 A, B , 并且图中的每条边的两个顶点分别属于 A 和 B , 则称 G 是一个二部图, 并记为 $G(A, B, E)$ 。注意到如果 A 与 B 集合的大小不同, 那么显然不存在完美匹配, 所以下面假设 A 与 B 包含的顶点个数相同, 即 $|A| = |B|$ 。




图 1: 一张二部图和一个完美匹配 (红色边)

1.2 代数化过程

以上面的图 1 为例, 我们先写出该二部图的邻接矩阵 M , 它可以用一个 5×5 的矩阵表达, 如果第 i 行第 j 列是 1, 说明从左边的第 i 个点到右边的第 j 个点有一条边¹。

$$M = \begin{bmatrix} \textcolor{red}{1} & 1 & 0 & 0 & 0 \\ 1 & 0 & \textcolor{red}{1} & 0 & 0 \\ 0 & \textcolor{red}{1} & 0 & 0 & 0 \\ 0 & 0 & 1 & \textcolor{red}{1} & 0 \\ 0 & 0 & 0 & 1 & \textcolor{red}{1} \end{bmatrix}.$$

如果我们把该图的完美匹配中的边在邻接矩阵中用红色标出, 不难发现, 这些边分别处于矩阵的不同行、不同列。这一性质很容易推广到一般的情况: 对于一个二部图 $G(A, B, E)$, 且 $|A| = |B| = n$,

¹需要注意, 此处二部图的邻接矩阵与一般图的邻接矩阵定义有区别

那么 G 存在一个完美匹配当且仅当其 $n \times n$ 的邻接矩阵中存在 n 个“1”，它们分别处于不同行、不同列。而“不同行、不同列”这样的性质，很容易让我们联想到方阵行列式的计算公式：

$$\det(M) = \sum_{\sigma \in S_n} (-1)^{\text{sgn}(\sigma)} \prod_{i=1}^n M_{i, \sigma(i)}.$$

观察上式，如果忽略掉求和式中的 $(-1)^{\text{sgn}(\sigma)}$ ，那么求和式的每一项就对应于一个可能的完美匹配：如果 $\prod_{i=1}^n M_{i, \sigma(i)}$ 为 1，则由排列 σ 可以得到一个完美匹配。但由于前面的符号项，两个完美匹配对应 1 可能正负抵消。我们可以得到这样一个结论：如果 $\det(M) \neq 0$ ，则存在完美匹配；如果 $\det(M) = 0$ ，则无法确定是否存在完美匹配。

事实上，之所以在计算 $\det(M)$ 时会出现正负抵消的问题，是因为 M 中的元素只有 0 和 1。如果我们不用 1 表示存在一条边，而是引入一个新的变量，那么 $\det(M)$ 就会变成一个多元多项式，因为变元不同，所以可以避免正负抵消。具体来看，在上面的例子中，将 M 中的非零元素替换成不同的变元，就得到下面的矩阵 M' ：

$$M'(x_{11}, \dots, x_{55}) = \begin{bmatrix} x_{11} & x_{12} & 0 & 0 & 0 \\ x_{21} & 0 & x_{23} & 0 & 0 \\ 0 & x_{32} & 0 & 0 & 0 \\ 0 & 0 & x_{43} & x_{44} & 0 \\ 0 & 0 & 0 & x_{54} & x_{55} \end{bmatrix}.$$

我们可以得到下面的定理：

定理 1. 二部图 G 存在完美匹配的充分必要条件是 $\det(M') \neq 0$ 。

证明 由行列式的定义，

$$\det(M') = \sum_{\sigma \in S_n} (-1)^{\text{sgn}(\sigma)} \prod_{i=1}^n x_{i, \sigma(i)}. \quad (1.1)$$

上式对置换群 S_n 中的所有置换 σ 求和，其中每一项都是带符号的 M' 中不同行不同列的 n 个元素的乘积单项式；根据上述的观察，这一项不为 0 当且仅当 G 中存在这 n 个元素对应的完美匹配。所以， G 中存在完美匹配的充分必要条件是 M' 的行列式不恒为 0，即 $\det(M') \neq 0$ 。□

而要判断多元多项式根与系数的关系，需要使用 Schwartz-Zippel 引理。

1.3 Schwartz-Zippel Lemma

定义 2 (多元多项式的次数). 多元多项式 P 中非零单项式的最高次数称为多元多项式 P 的次数，记为 $\deg(P)$ 。

例 1 令 $P(x_1, x_2, x_3, x_4) = x_1^7 x_2^3 x_3 + x_1 x_2^8 x_3^6$ ，则最高次单项式为 $x_1 x_2^8 x_3^6$ ，故 $\deg(P) = 15$ 。

定理 3 (Schwartz-Zippel Lemma). 设 $P(z_1, \dots, z_n)$ 为域 \mathcal{F} 上的非零多项式，即

$$P(z_1, \dots, z_n) \in \mathcal{F}[z_1, \dots, z_n], \text{ 且 } P \neq 0$$

S 为域 \mathcal{F} 的有限子集，即 $S \subseteq \mathcal{F}$ ，且 $|S| < +\infty$ 。若独立随机地从 S 中选取 r_1, \dots, r_n ，则有

$$\Pr(P(r_1, \dots, r_n) = 0) \leq \frac{\deg(P)}{|S|}$$

证明 对多项式 $P(z_1, \dots, z_n)$ 的变量个数 n 进行归纳:

当 $n = 1$ 时, 由代数学基本定理, $P(z_1) = 0$ 在 S 上至多有 $\deg(P)$ 个根。因此

$$\Pr(P(r_1) = 0) \leq \frac{\deg(P)}{|S|}$$

假设原命题对变量个数小于等于 n 的多项式都成立, 现考虑变量个数为 $n+1$ 的多项式 $P(z_1, \dots, z_{n+1})$ 。

$P(z_1, \dots, z_{n+1})$ 可以写成关于变元 z_1 的多项式形式, 每一项的系数都是一个 n 元多项式, 假设 z_1 最大次数为 d , 则有

$$\begin{aligned} P(z_1, z_2, \dots, z_{n+1}) = & z_1^d \cdot P_d(z_2, \dots, z_{n+1}) + z_1^{d-1} \cdot P_{d-1}(z_2, \dots, z_{n+1}) + \\ & \dots + z_1 \cdot P_1(z_2, \dots, z_{n+1}) + P_0(z_2, \dots, z_{n+1}) \end{aligned} \quad (1.2)$$

当 $\Pr(P(r_1, r_2, \dots, r_{n+1}) = 0)$ 时, 我们对 $P_d(r_2, \dots, r_{n+1})$ 是否为 0 分类讨论, 得到下面的概率表达式

$$\begin{aligned} \Pr(P(r_1, r_2, \dots, r_{n+1}) = 0) &= \Pr\left(P(r_1, r_2, \dots, r_{n+1}) = 0, P_d(r_2, \dots, r_{n+1}) = 0\right) \\ &\quad + \Pr\left(P(r_1, r_2, \dots, r_{n+1}) = 0, P_d(r_2, \dots, r_{n+1}) \neq 0\right) \\ &\leq \Pr\left(P_d(r_2, \dots, r_{n+1}) = 0\right) \\ &\quad + \Pr\left(P(r_1, r_2, \dots, r_{n+1}) = 0, P_d(r_2, \dots, r_{n+1}) \neq 0\right) \end{aligned} \quad (1.3)$$

由归纳假设

$$\Pr(P_d(r_2, \dots, r_{n+1}) = 0) \leq \frac{\deg(P_d)}{|S|} = \frac{\deg(P) - d}{|S|} \quad (1.4)$$

又由式 (1.2), 当 z_2, \dots, z_{n+1} 的取值给定时, 即 $(z_2, \dots, z_{n+1}) = (b_2, \dots, b_{n+1})$, 此时 $P(z_1, z_2, \dots, z_{n+1})$ 可以视为关于变量 z_1 的一元 d 次多项式, 记为 $Q_{b_2, \dots, b_{n+1}}(z_1)$ 。则有

$$\begin{aligned} &\Pr\left(P(r_1, r_2, \dots, r_{n+1}) = 0, P_d(r_2, \dots, r_{n+1}) \neq 0\right) \\ &\leq \sum_{b_2, \dots, b_{n+1}} \Pr(r_2 = b_2, \dots, r_{n+1} = b_{n+1}) \cdot \Pr(Q_{b_2, \dots, b_{n+1}}(r_1) = 0) \\ &\leq \sum_{b_2, \dots, b_{n+1}} \Pr(r_2 = b_2, \dots, r_{n+1} = b_{n+1}) \cdot \frac{\deg(Q_{b_2, \dots, b_{n+1}})}{|S|} \\ &\leq \frac{d}{|S|} \end{aligned} \quad (1.5)$$

由式 (1.3), 式 (1.4) 和式 (1.5) 可得,

$$\begin{aligned} \Pr(P(r_1, r_2, \dots, r_{n+1}) = 0) &\leq \frac{\deg(P) - d}{|S|} + \frac{d}{|S|} \\ &= \frac{\deg(P)}{|S|} \end{aligned}$$

□

1.4 随机算法

给定一个二部图 $G = (A, B, E)$, 其中 $|A| = |B| = n$, 我们利用 1.1 中的分析以及 Schwartz-Zippel 引理给出一个随机算法判定 G 中是否有完美匹配, 具体描述如下:

1. 构造图 G 的代数化邻接矩阵 M'
2. 在 n^2 到 $2n^2$ 之间找一个素数 p , 在有限域 \mathcal{F}_p 上独立均匀随机地选取 $r_{11}, \dots, r_{nn} \in \mathcal{F}_p$, 计算 $\det(M'(r_{11}, \dots, r_{nn}))$
3. 如果结果不为 0, 则输出 “存在”; 如果结果为 0, 则输出 “不存在”。

注: 由 *Bertrand-Chebyshev* 定理, 对于任意大于 1 的整数 m , 一定存在一个素数 p 满足 $m < p < 2m$, 因此一定可以找到这样的素数

由定理 1, 如果图 G 不存在完美匹配, 则算法一定输出 “不存在”; 但当 G 中存在完美匹配时, 虽然多项式 $\det(M')$ 不恒为 0, 但由于 r_{11}, \dots, r_{nn} 是随机选取的, 它有可能恰好是这个多项式的根, 从而算法有可能出错。下面分析算法出错的概率。

定理 4. 当 G 存在完美匹配时, $\Pr_{r_{11}, \dots, r_{nn}}(\det(r_{11} \dots r_{nn}) = 0) \leq \frac{1}{n}$ 。

证明 当 G 存在完美匹配时, 多项式 $P = \det(M')$ 不恒为 0。令 $S = \mathcal{F}_p$, 则 S 为有限集, 由引理 3, 对于独立均匀随机选取的 r_{11}, \dots, r_{nn} 有

$$\Pr_{r_{11}, \dots, r_{nn}}(P(r_{11} \dots r_{nn}) = 0) \leq \frac{\deg(P)}{|S|} = \frac{n}{p} \leq \frac{1}{n}. \quad (1.6)$$

□

算法的执行过程依赖于两个子过程: 在 n^2 和 $2n^2$ 之间找一个素数, 以及求一个数值矩阵的行列式。使用枚举法即可找到此素数, 且素数判定存在多项式时间算法; 求矩阵的行列式也存在多项式时间算法。所以整个算法是多项式时间的, 从而是一个 RP 算法。

上述寻找素数的过程也可以进行一些改进: 在 n^2 和 $2n^2$ 之间均匀随机选择一个整数 k , 用素数判定算法判断 k 是否为素数; 反复执行这个过程直到找到素数为止。事实上, 如果设 $\pi(m) = \{p \leq m : p \text{ 是素数}\}$ 为不超过正整数 m 的素数的个数, 则根据素数定理有

$$\pi(m) \sim \Theta\left(\frac{m}{\ln m}\right). \quad (1.7)$$

从而可以知道, 在 n^2 和 $2n^2$ 之间有 $\Theta(\frac{1}{\ln n})$ 个素数。类比掷硬币的模型, 在期望意义下, 平均做 $\Theta(\ln n)$ 次这样的均匀随机选择就能得到一个素数。

Homework: (红-蓝匹配问题) 为二部图的红蓝匹配问题设计一个多项式时间的随机算法。问题描述: 二部图 G 的边被染成了红和蓝两种颜色, 给定 $1 \leq k \leq n$, 判定 G 中是否存在一个完美匹配 M , 使得 M 中恰有 k 条红边和 $n - k$ 条蓝边。

2 期望方法

2.1 最大割问题

定义 5 (割, 割集). 给定图 $G = (V, E)$, 定义图 G 上的割为顶点集 A 和 B 组成的二元组 (A, B) , 其中 $A \cap B = \emptyset$, $A \cup B = V$ 。由割 (A, B) 可定义割集 $E(A, B) = \{(u, v) \in E | u \in A, v \in B\}$,

最大割问题 (Max-Cut Problem): 给定图 $G = (V, E)$, 求使得割集 $E(A, B)$ 元素个数最多的割 (A, B) 。

最大割的判定问题: 给定图 $G = (V, E)$ 以及正整数 k , 判定是否存在元素个数恰好为 k 的割集 $E(A, B)$ 。

最大割的判定问题为 NP-完全问题。最大割问题为 NP-难的问题, 目前还没有已知的确定性多项式时间算法。下面介绍一个关于最大割问题的近似算法。

算法描述 (求解最大割问题的近似算法). 输入图 $G = (V, E)$, 对于 V 中的任一顶点 v , 以 $\frac{1}{2}$ 的概率将 v 放入顶点集 A 中, 以 $\frac{1}{2}$ 的概率将 v 放入顶点集 B 中。

定理 6. 给定图 $G = (V, E)$, 设随机变量 $E(A, B)$ 为上述算法输出的割集, 设 opt 为图 G 的最大割集的大小。则有

$$\frac{\mathbb{E}(|E(A, B)|)}{opt} \geq \frac{1}{2}$$

证明 定义随机变量 $X_i, i = 1, \dots, |V|$,

$$X_i = \begin{cases} 0, & \text{顶点 } u_i \in A \\ 1, & \text{顶点 } u_i \in B \end{cases}$$

则有 $\Pr(X_i = 0) = \Pr(X_i = 1) = \frac{1}{2}$ 。

对于边集 E 中的任一条边 (u_i, u_j) , 有

$$\Pr((u_i, u_j) \in E(A, B)) = \Pr(X_i \neq X_j) = \frac{1}{2}$$

对于任意的 $(u_i, u_j) \in E$, 定义随机变量 $Y_{i,j}$ 如下,

$$Y_{i,j} = \begin{cases} 0, & (u_i, u_j) \notin E(A, B) \\ 1, & (u_i, u_j) \in E(A, B) \end{cases}$$

则有 $\mathbb{E}(Y_{i,j}) = \frac{1}{2}$

$$\begin{aligned} \mathbb{E}(|E(A, B)|) &= \mathbb{E} \left[\sum_{(u_i, u_j) \in E} Y_{i,j} \right] \\ &= \sum_{(u_i, u_j) \in E} \mathbb{E}[Y_{i,j}] \\ &= \frac{|E|}{2} \end{aligned}$$

又 $opt \leq |E|$, 因此

$$\frac{\mathbb{E}(|E(A, B)|)}{opt} \geq \frac{1}{2}$$

□

2.2 期望方法去随机化

对于最大割问题，我们还可以通过去随机化，将随机算法转换成确定型算法，并且该算法的表现不劣于随机算法。我们已知随机算法中 $\mathbb{E}(|E(A, B)|) = \frac{|E|}{2}$ 。记 $|E(A, B)| = Y$ ，依据期望的全概率分解公式，有

$$\begin{aligned}\mathbb{E}(Y) &= \Pr(X_1 = 1)\mathbb{E}(Y|X_1 = 1) + \Pr(X_1 = 0)\mathbb{E}(Y|X_1 = 0) \\ &= \frac{1}{2}\mathbb{E}(Y|X_1 = 1) + \frac{1}{2}\mathbb{E}(Y|X_1 = 0)\end{aligned}\quad (2.1)$$

去随机化的关键在于上式中 $\mathbb{E}(Y|X_1 = 0)$ 和 $\mathbb{E}(Y|X_1 = 1)$ 是可以直接计算得到的。以 $\mathbb{E}(Y|X_1 = 0)$ 为例，由于 $X_1 = 0$ 表示顶点 u_1 在 A 中，对于任意一条边 (u_i, u_j) ，若该边与 u_1 相连，则它最终是否为割边取决于另一个端点是否在 B 中，所以随机变量 $Y_{i,j}$ 对条件概率贡献 $\frac{1}{2}$ ；若边 (u_i, u_j) 与 u_1 不相连，则它对应的随机变量 $Y_{i,j}$ 对条件概率贡献 $\frac{1}{2}$ 。

事实上，当任何 k 个顶点 $u_{i_1}, u_{i_2}, \dots, u_{i_k}$ 已被确定所属（即去随机化）的情况下，对应的条件期望 $\mathbb{E}(Y|X_{i_1} = x_{i_1}, \dots, X_{i_k} = x_{i_k})$ 都可以结合图的具体结构直接计算——考虑图中所有边 (u_i, u_j) ，若两个顶点都已被去随机化，则该边是否为割便已清楚，对应随机变量 $Y_{i,j}$ 贡献 0 或 1；若一个或零个顶点被去随机化，对应随机变量 $Y_{i,j}$ 贡献 $\frac{1}{2}$ 。

所以式 2.1 中，两个条件期望计算后可知其中较大者。不妨设 $\mathbb{E}(Y|X_1 = 0) \leq \mathbb{E}(Y|X_1 = 1)$ ，于是有

$$\begin{aligned}\mathbb{E}(Y) &\leq \mathbb{E}(Y|X_1 = 0) \\ &= \mathbb{E}(Y|X_1 = 0, X_2 = 0)\Pr(X_2 = 0|X_1 = 0) + \mathbb{E}(Y|X_1 = 0, X_2 = 1)\Pr(X_2 = 1|X_1 = 0) \\ &= \frac{1}{2}\mathbb{E}(Y|X_1 = 0, X_2 = 0) + \frac{1}{2}\mathbb{E}(Y|X_1 = 0, X_2 = 1)\end{aligned}$$

以同样方式计算两个条件期望的值并取较大者，不断重复下去，最终将所有 X_i 去随机化，便得到了一个确定的割，且割集大小 $|E(A, B)| \geq \mathbb{E}(E(A, B)) = \frac{m}{2}$ 。

3 LP 中的 Rounding 方法

3.1 Max-SAT 问题

一个包含 n 个布尔变量的合取范式 $\varphi(x_1, \dots, x_n) = c_1 \wedge c_2 \wedge \dots \wedge c_m$ 是由 m 个子句 c_1, \dots, c_m 合取得到的。每个子句是若干个文字（变量 x_i 或变量的非 \bar{x}_i ）的析取，形如 $c_i = x_1 \vee \bar{x}_3 \vee x_4 \vee x_5$ 。Max-SAT 问题关心在各种可能的真值赋值下，最多能有多少个子句为真。

我们先考虑 Max-SAT 问题的一个最简单的近似算法：对 n 个变量随机赋值为 T 或 F ，输出满足的子句数。

对于给定的公式 φ ，定义其 Max-SAT 问题的最优解为 opt ，算法结果为随机变量 Y 。设子句 c_i 的真假值对应随机变量 Y_i

$$Y_i = \begin{cases} 0, & c_i = F \\ 1, & c_i = T \end{cases}$$

于是有 $Y = \sum_{i=1}^m Y_i$ 。考虑 Y_i ，假设 c_i 中有 t_i 个文字，在变量的随机赋值下， $\mathbb{E}(Y_i) = \Pr(c_i = T) = 1 - \frac{1}{2^{t_i}} = p_i$ ，故 $\mathbb{E}(Y) = \sum_{i=1}^m p_i \geq mp$ ，其中 p 是 p_i 中的最小值。而 $opt \leq m$ ，所以

$$\frac{\mathbb{E}(Y)}{opt} \geq p$$

可以看到, p 取决于各个子句中最短者, 且该子句越短 p 越小。此外, 该随机算法也可以去随机化得到一个确定性算法, 有兴趣的同学可以课下研究。

3.2 LP + rounding

事实上, Max-SAT 问题可以编码成整数线性规划 (ILP) 问题进行求解。但我们知道, 线性规划 (LP) 存在多项式时间算法, 但 ILP 是一个 NP 完全问题, 没有多项式时间算法。下面我们通过随机算法利用 LP 和 rounding 的方法找 ILP 问题的解。

算法描述 以下面的 Max-SAT 具体问题为例, 其中每一个变量记为 x_i , 且 $x_1, \dots, x_n \in \{0, 1\}$, 记每一个子式为 y_j ($j = 1, \dots, m$), 有 $y_1, \dots, y_m \in \{0, 1\}$ 。

$$\begin{aligned}\varphi &= (x_1 \vee \bar{x}_2 \vee x_3) \wedge (x_1 \vee x_4) \wedge (\bar{x}_2 \vee x_4 \vee x_6 \vee x_7) \wedge x_5 \\ &= y_1 \wedge y_2 \wedge y_3 \wedge y_4\end{aligned}$$

那么原 Max-SAT 问题可以写成 ILP 的形式:

$$\begin{aligned}\max \quad & y_1 + y_2 + y_3 + y_4 \\ \text{s.t.} \quad & \begin{cases} y_1 \leq x_1 + (1 - x_2) + x_3 \\ y_2 \leq x_1 + x_4 \\ y_3 \leq (1 - x_2) + x_4 + x_6 + x_7 \\ y_4 \leq x_5 \\ x_1, \dots, x_7 \in \{0, 1\} \\ y_1, \dots, y_4 \in \{0, 1\} \end{cases}\end{aligned}$$

注意到上面 ILP 与 LP 的区别只在于 x_i, y_j 都是 0, 1 变量, 我们可以把这个条件放松, 让 $x_i, y_j \in [0, 1]$, 从而得到了一个 LP 问题, 但注意, 这个松弛的过程会扩大解空间, 有可能得到的解不是原 ILP 问题的解。

把 ILP 松弛成 LP 形式:

$$\begin{aligned}\max \quad & y_1 + y_2 + y_3 + y_4 \\ \text{s.t.} \quad & \begin{cases} y_1 \leq x_1 + (1 - x_2) + x_3 \\ y_2 \leq x_1 + x_4 \\ y_3 \leq (1 - x_2) + x_4 + x_6 + x_7 \\ y_4 \leq x_5 \\ x_1, \dots, x_7 \in [0, 1] \\ y_1, \dots, y_4 \in [0, 1] \end{cases}\end{aligned}$$

先求解这一 LP 问题, 记最优值为 $y_{LP}^{(opt)}$, 相应的最优解记为: $x_1^*, x_2^*, \dots, x_7^*, y_1^*, \dots, y_4^* \in [0, 1]$. 则: $y_{LP}^{(opt)} = y_1^* + y_2^* + y_3^* + y_4^*$. 相应的, 将 ILP 问题的最优值记为 $y_{ILP}^{(opt)}$. 由于搜索范围扩大, 所以显然有 $y_{LP}^{(opt)} \geq y_{ILP}^{(opt)}$.

接下来, 通过随机舍入的方法, 将 LP 的最优解**整数化**, 得到一组 ILP 的解。LP 问题的最优解 $x_1^*, \dots, x_7^* \in [0, 1]$, 可以看作是一组 0-1 随机变量 X_i 取值为 1 的概率:

$$\Pr(X_i = 1) = x_i^*, \quad \Pr(X_i = 0) = 1 - x_i^*, \quad i = 1, \dots, 7$$

定义 0-1 随机变量 $Y_j, j = 1, \dots, 4$, 表示取定 X_i 后, 第 j 个子句是否被满足。

算法近似比分析 下面分析由随机算法得到的解对应的目标函数值和 $y_{ILP}^{(opt)}$ 之间的关系。考虑 Max-SAT 中每个子句可满足的概率, 以第一个子句为例: $c_1 = x_1 \vee \bar{x}_2 \vee x_3$,

$$\begin{aligned}
 \Pr(Y_1 = 1) &= 1 - \Pr(Y_1 = 0) \\
 &= 1 - \Pr(X_1 = 0, X_2 = 1, X_3 = 0) \\
 &= 1 - (1 - x_1^*) x_2^* (1 - x_3^*) \\
 &\geq 1 - \left[\frac{(1 - x_1^*) + x_2^* + (1 - x_3^*)}{3} \right]^3 \quad (\text{根据均值不等式}) \\
 &= 1 - \left[\frac{3 - (x_1^* + (1 - x_2^*) + x_3^*)}{3} \right]^3 \\
 &= 1 - \left(1 - \frac{y_1^*}{3}\right)^3
 \end{aligned}$$

更一般的, 对于有 k 个文字的子句 c_i :

$$\Pr(Y_i = 1) = 1 - \Pr(Y_i = 0) \geq 1 - \left(1 - \frac{y_i^*}{k}\right)^k \geq \left(1 - \frac{1}{e}\right) y_i^*.$$

因此随机算法得到的一组整数解, 对应的目标函数值的期望为,

$$\mathbb{E}(Y_1 + \dots + Y_m) = \sum_{i=1}^m \Pr(Y_i = 1) \geq \left(1 - \frac{1}{e}\right) \sum_{i=1}^m y_i^* = \left(1 - \frac{1}{e}\right) y_{LP}^{(opt)} \geq \left(1 - \frac{1}{e}\right) y_{ILP}^{(opt)}$$

故近似比为 $(1 - \frac{1}{e})$ 。